

Documento de Arquitetura

Pipeline de Análise de Acidentes de Trânsito em Rodovias Federais

Disciplina: Fundamentos de Big Data

Instituição: CESAR School

Data: Abril de 2026

1. Introdução

Este documento descreve a arquitetura do pipeline de dados desenvolvido para analisar acidentes de trânsito nas rodovias federais brasileiras. O objetivo é identificar padrões e fatores de risco associados à gravidade dos acidentes, com base nos dados públicos da Polícia Rodoviária Federal (PRF).

2. Problema

Acidentes de trânsito em rodovias federais representam um grave problema de segurança pública no Brasil. Este projeto busca responder: **quais fatores estão mais associados a acidentes graves ou fatais?**

3. Fonte de Dados

Atributo	Detalhe
Dataset	DATATRAN 2025 - Dados de Acidentes em Rodovias Federais
Origem	Polícia Rodoviária Federal (PRF) - Dados Abertos
Formato	CSV (separado por ``, encoding UTF-8
Volume	~75.000 registros
Ingestão	Google Sheets (intermediário) → Pandas → Apache Spark


Principais colunas:

- data_inversa

- horario
- uf
- br
- km
- tipo_acidente
- classificacao_acidente
- condicao_meteorologica
- tipo_pista
- mortos
- feridos_graves
- feridos_leves.

4. Arquitetura do Pipeline — Medallion

O pipeline segue a arquitetura **Medallion** (camadas Landing → Bronze → Silver → Gold), executado no ambiente **Databricks Community Edition**.



5. Detalhamento de Cada Camada

5.1 Landing

- **Objetivo:** Ingestão dos dados brutos sem transformações.

- **Processo:** Leitura do CSV via URL do Google Sheets com `pandas.read_csv()`, preservando encoding UTF-8.
- **Armazenamento:** Conversão para Spark DataFrame e persistência como tabela Delta (`acidentes.default.datatran_2025`).
- **Ferramentas:** Python, Pandas, PySpark, Delta Lake.

5.2 Bronze

- **Objetivo:** Padronização mínima e rastreabilidade da ingestão.
- **Processo:**
 - Normalização de nomes de colunas (lowercase, underscores).
 - Adição de metadados: ``ingestion_timestamp``, ``ingestion_id`` (UUID), ``source_table``.
 - Registro de log de ingestão (`acidentes.bronze.ingestion_log`): ID, tabela origem/destino, quantidade de linhas, timestamp.
- **Armazenamento:** `acidentes.bronze.acidentes_2025` (formato Delta).
- **Ferramentas:** PySpark, Delta Lake, ``uuid``.

5.3 Silver

- **Objetivo:** Dados limpos, confiáveis e enriquecidos para análise.
- **Processo:**
 - Remoção de duplicatas (colunas de negócio, excluindo metadados).
 - Tratamento de nulos e valores inválidos.
 - Correção de ``classificacao_acidente`` com base em contagem de mortos/feridos.
 - Remoção de colunas irrelevantes (``regional``, ``delegacia``, ``uop``, ``latitude``, ``longitude``).
 - Conversão de tipos: ``data_inversa`` → ``DateType``, ``horario`` → ``TimestampType``.
 - Criação de colunas derivadas a partir de ``data`` e ``timestamp_acidente``:
 - ``ano``
 - ``mes``
 - ``dia_do_mes``
 - ``hora``
 - ``periodo_dia``
 - Observação: a coluna ``dia_semana`` e o ``turno`` mencionados em versões anteriores deste documento não são materializados na Silver. O equivalente funcional do ``turno`` é a coluna ``periodo_dia``. A coluna ``dia_semana`` é derivada apenas na camada Gold, dentro de ``dim_tempo``.
 - Renomeação ``uso_solo`` → ``tipo_uso_solo``, com mapeamento ``Sim`` → ``Urbano``, ``Não`` → ``Rural``, demais valores → ``Desconhecido``.

- Remoção das colunas `fase\_dia` (redundante com `periodo\_dia`) e `sentido\_via` (não utilizada nas análises).
- Consolidação de feridos: as colunas `feridos\_leves` e `feridos\_graves` são removidas, mantendo-se apenas `feridos` (soma das duas, já presente no dataset).
- Normalização de texto (`trim` + `upper`) nas colunas categóricas: `causa\_acidente`, `tipo\_acidente`, `classificacao\_acidente`, `condicao\_meteorologica`, `tipo\_pista`, `tracado\_via`, `municipio`, `uf`.
- Particionamento físico da tabela Silver por `ano` e `mes` ao gravar em Delta.
- Log próprio de ingestão da Silver: além do log da Bronze, é gravada uma tabela `acidentes.silver.ingestion\_log` com `ingestion\_id`, `source\_table`, `target\_table`, `row\_count`, `layer` e `log\_timestamp`.
- Conversão de `km` de string (vírgula decimal) para `DoubleType`.
- Filtro: apenas rodovias federais (`br != 0`).
- Reutilização dos termos de governança da camada bronze.
- **Armazenamento:** `acidentes.silver.acidentes\_2025` (formato Delta).
- **Ferramentas:** PySpark, Delta Lake, funções de data/hora do Spark.

5.4 Gold

- **Objetivo:** Modelo dimensional (Star Schema) pronto para consumo analítico, com agregações e visualizações.
- **Modelagem:** uma tabela fato e cinco dimensões, com chaves substitutas (`\*\_sk`) geradas via `md5` para chaves de negócio compostas e via concatenação `aaaa+mm+dd+hh` para a dimensão de tempo.
- **Tabelas materializadas (Delta) em acidentes.gold:**

Tabela	Conteúdo principal
dim_tempo	tempo_sk, data, ano, mes, dia_do_mes, dia_semana, hora, periodo_dia, is_final_semana, turno, trimestre
dim_localização	localizacao_sk, uf, rodovia_br, municipio, regioao (Norte/Nordeste/Centro-Oeste/Sudeste/Sul)
dim_condicoes_via	condicoes_via_sk, tipo_pista, tracado_via, tipo_uso_solo, nivel_risco_pista
dim_ambiente	ambiente_sk, condicao_meteorologica, tipo_condicao (Normal/Adverso/Outro)

dim_tipo_acidente	tipo_acidente_sk, tipo_acidente, causa_acidente, classificacao_acidente, nivel_gravidade (Fatal/Grave/Leve/Sem Vítimas)
fato_acidentes	acidente_id, FKs para as 5 dimensões, métricas (qtd_pessoas, qtd_mortos, qtd_feridos, qtd_ilesos, qtd_ignorados, qtd_veiculos, km), métricas calculadas (qtd_vitimas, flag_fatal, flag_com_feridos, indice_gravidade)

- **Análises e visualizações entregues:**
 - Top 20 rodovias federais por número absoluto de mortes em acidentes fatais.
 - Mapa de calor (heatmap) de mortes por dia da semana × hora do dia.
 - Condições meteorológicas: taxa de letalidade e gráfico comparativo de frequência vs letalidade.
 - Top 15 causas de acidente por volume de mortes e por taxa de letalidade.
 - Top 15 tipos de acidente por taxa de letalidade.
 - Associação tipo × causa (linhas) entre as combinações mais letais.
 - Sazonalidade mensal: mortes, acidentes fatais e taxa de mortalidade por mês.
 - Resumo executivo (KPIs) com totais, top 3 rodovias, top 3 horários e top 3 dias da semana mais perigosos.
- **Ferramentas:** PySpark, Pandas, Matplotlib, Seaborn.

6. Tecnologias Utilizadas

Tecnologia	Função
Python 3	Linguagem principal
Pandas	Leitura e pré-processamento inicial do CSV
Apache Spark (PySpark)	Processamento distribuído das transformações
Delta Lake	Armazenamento confiável com suporte a versionamento
Databricks Community Edition	Ambiente de execução dos notebooks
Google Sheets	Intermediário para hospedar o CSV raw
Github	Versionamento de código e documentação

Jupyter Notebooks	Desenvolvimento interativo do pipeline
Matplotlib / Seaborn	Visualizações na camada Gold

7. Tecnologias Pagas para Refinamento

As tecnologias abaixo poderiam ampliar a capacidade do pipeline em um ambiente de produção:

Tecnologia	Função	Justificativa
Databricks	Clusters maiores e Jobs agendados	Permite execução automática e escalável da pipeline sem intervenção manual
Azure Data Lake Storage	Armazenamento distribuído em nuvem	Substitui o armazenamento local do Databricks Community por storage persistente e escalável
Apache Kafka	Streaming de dados em tempo real	Permitiria ingestão contínua de boletins de acidente assim que registrados
dbt (Data Build Tool)	Transformações SQL versionadas	Melhor governança e documentação automática das transformações Silver/Gold
Power BI	Dashboards interativos	Visualizações mais ricas e acessíveis para tomadores de decisão não-técnicos

8. Estrutura do Repositório

```

pipeline-analise-acidentes-transito/
├── data/                                # Amostras dos dados (CSV)
│   └── datatran-2025.csv
├── src/                                # Notebooks do pipeline
│   ├── 01_landing_to_bronze.ipynb
│   ├── 02_bronze_to_silver.ipynb
│   └── 03_silver_to_gold.ipynb
├── docs/                               # Diagramas e documentos de arquitetura
└── arquitetura.pdf

```

9. Divisão de Tarefas da Equipe

Membro	Responsabilidade
Matheus Canel	Criação e desenvolvimento do pipeline
Edmar Alencar	Criação da documentação
Arthur Reis	Levantamento e estudo do tema
Luiz Felipe Soriano	Apoio na estruturação do pipeline
Gabriel Moura	Organização do ReadMe, estruturação do repositório e Slides
Diego Escorel	Escolha do dataset e exploração dos dados

10. Checklist

Formulário com o estado de cada parte do pipeline:

- Ingestão: Finalizado
- Armazenamento: Finalizado
- Transformação: Finalizado

11. Referências

- PRF — Dados Abertos: <https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos>
- Databricks Delta Lake: <https://delta.io>
- Arquitetura Medallion: <https://www.databricks.com/glossary/medallion-architecture>